



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی
مهندسی کامپیوتر

امتیازدهی خودکار ASPECT بر روی تصاویر CT با استفاده از یادگیری ژرف

نگارش

مهتا فطرت

استاد راهنما

دکتر حمیدرضا ربیعی

تیر ۱۴۰۲

به نام خدا
دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی

این پایان نامه به عنوان تحقق بخشی از شرایط دریافت درجه کارشناسی است.

عنوان: امتیازدهی خودکار ASPECT بر روی تصاویر CT با استفاده از یادگیری ژرف
نگارش: مهتا فطرت

کمیته ممتحنین

استاد راهنما: دکتر حمیدرضا ربیعی امضاء:

استاد مشاور: استاد مشاور امضاء:

استاد مدعو: استاد ممتحن امضاء:

تاریخ:

سپاس

از استاد بزرگوارم که با کمک‌ها و راهنمایی‌های بی‌دریغشان، مرا در به سرانجام رساندن این پایان‌نامه یاری داده‌اند، تشکر و قدردانی می‌کنم. همچنین از همکاران عزیزی که با راهنمایی‌های خود در بهبود نگارش این نوشتار سهیم بوده‌اند، صمیمانه سپاسگزارم.

چکیده

سکته‌ی مغزی به عنوان دومین عامل مرگ و میر در جهان شناخته می‌شود. این عارضه می‌تواند آسیب‌های دائمی و جبران‌ناپذیری برای افراد مبتلا به همراه داشته‌باشد. بنابراین، تشخیص سریع سکته‌ی مغزی و درمان در مراحل اولیه، از اهمیت بسیار بالایی برخوردار است. امتیاز ASPECT یک معیار برای ارزیابی وخامت سکته‌ی مغزی بر روی تصاویر CT می‌باشد. اما تشخیص صحیح وخامت سکته بر روی تصاویر اولیه، که نواحی آسیب‌دیده به خوبی در آن ظاهر نمی‌شود، حتی برای متخصصین این حوزه، امری چالش‌برانگیز است. در این پژوهش یک راهکار تشخیص خودکار امتیاز ASPECT، مبتنی بر روش‌های یادگیری ژرف ارائه می‌شود که می‌تواند در تعیین وخامت سکته توسط متخصصین این امر ASPECT راهگشا باشد و سرعت و دقت تشخیص و تجویز روش‌های درمانی را بهبود ببخشد. پژوهش حاضر، یک روش نظام‌مند برای پیش‌پردازش تصاویر CT مغزی پیشنهاد می‌کند که می‌تواند در سایر پژوهش‌ها بر روی تصاویر مغزی مورد استفاده قرار بگیرد. در ادامه، یک شبکه‌ی عصبی عمیق، مبنی بر مدل‌های پیش‌آموزش‌یافته طراحی می‌شود و عملکرد این شبکه بر روی داده‌های نمونه بررسی و تحلیل می‌گردد.

کلیدواژه‌ها: پایان‌نامه، حروف چینی، قالب، زی‌پرشین

فهرست مطالب

۱	مقدمه	۱
۱	۱-۱ تعریف مسئله	۱
۱	۲-۱ اهمیت موضوع	۱
۲	۳-۱ ادبیات موضوع	۲
۲	۴-۱ اهداف پژوهش	۲
۲	۵-۱ ساختار پایان نامه	۲
۳	۲ مفاهیم اولیه	۳
۳	۱-۲ نحوه‌ی نگارش	۳
۳	۲-۱-۱ پرونده‌ها	۳
۳	۲-۱-۲ عبارات ریاضی	۳
۴	۲-۱-۳ علائم ریاضی پرکاربرد	۴
۵	۲-۱-۴ لیست‌ها	۵
۵	۲-۱-۵ درج شکل	۵
۶	۲-۱-۶ درج جدول	۶
۶	۲-۱-۷ درج الگوریتم	۶
۶	۲-۱-۸ محیط‌های ویژه	۶
۷	۲-۲ برخی نکات نگارشی	۷

۷	۲-۲-۱ فاصله‌گذاری
۷	۲-۲-۲ شکل حروف
۸	۲-۲-۳ جدانویسی
۱۰	۳ کارهای پیشین
۱۰	۳-۱ مسائل خوشه‌بندی
۱۲	۳-۲ خوشه‌بندی k -مرکز
۱۴	۳-۳ مدل جویبار داده
۱۵	۳-۴ تقریب‌پذیری
۱۶	۴ نتایج جدید
۱۷	۵ نتیجه‌گیری
۱۸	مراجع
۱۸	واژه‌نامه
۲۰	آ مطالب تکمیلی

فهرست جدول‌ها

۶	۱-۲ عملگرهای مقایسه‌ای
۱۵	۱-۳ نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی

فهرست شکل‌ها

۵	۲-۱ یک گراف و پوشش رأسی آن
۵	۲-۲ نمونه شکل ایجادشده توسط نرم‌افزار Ipe
۱۲	۳-۱ نمونه‌ای از مسئله‌ی ۲-مرکز
۱۳	۳-۲ نمونه‌ای از مسئله‌ی ۲-مرکز با داده‌های پرت

فصل ۱

مقدمه

نخستین فصل یک پایان‌نامه به معرفی مسئله، بیان اهمیت موضوع، ادبیات موضوع، اهداف پژوهش و معرفی ساختار پایان‌نامه می‌پردازد. در این فصل نمونه‌ی مختصری از مقدمه آورده شده است.

۱-۱ تعریف مسئله

نگارش یک پایان‌نامه علاوه بر بخش‌های پژوهش و آماده‌سازی محتوا، مستلزم رعایت نکات دقیق فنی و نگارشی است که در تهیه‌ی یک پایان‌نامه‌ی موفق بسیار کلیدی و مؤثر است. از آن جایی که بسیاری از نکات فنی مانند قالب کلی صفحات، شکل و اندازه‌ی قلم، صفحات عنوان و غیره در تهیه‌ی پایان‌نامه‌ها یکسان است، می‌توان با ارائه‌ی یک قالب حروف‌چینی استاندارد نگارش پایان‌نامه‌ها را تا حد بسیار زیادی بهبود بخشید.

۲-۱ اهمیت موضوع

وجود قالب استاندارد برای نگارش پایان‌نامه از جهات مختلف حائز اهمیت است، از جمله:

- ایجاد یک‌نواختی در قالب کلی صفحات و شکل و اندازه‌ی قلم‌ها
- تسهیل نگارش پایان‌نامه با در اختیار گذاشتن یک قالب اولیه
- تولید خودکار صفحات دارای بخش‌های تکراری نظیر صفحات ابتدایی و انتهایی پایان‌نامه

- پیش‌گیری از برخی خطاهای مرسوم در نگارش پایان‌نامه

۳-۱ ادبیات موضوع

اکثر دانشگاه‌های معتبر قالب استاندارد برای تهیه‌ی پایان‌نامه در اختیار دانشجویان خود قرار می‌دهند. این قالب‌ها عموماً مبتنی بر نرم‌افزارهای متداول حروف‌چینی نظیر لاتک و مایکروسافت ورد هستند. لاتک^۱ یک نرم‌افزار متن‌باز قوی برای حروف‌چینی متون علمی است. [؟، ؟] در این نوشتار از نرم‌افزار حروف‌چینی زی‌تک^۲ و افزونه‌ی زی‌پرشین^۳ استفاده شده است.

۴-۱ اهداف پژوهش

کتابخانه‌ی مرکزی دانشگاه صنعتی شریف دستورالعمل جامعی را در خصوص نحوه‌ی تهیه‌ی پایان‌نامه‌ی کارشناسی ارشد و رساله‌ی دکتری ارائه کرده است. در این نوشتار سعی شده است قالب استاندارد برای تهیه‌ی پایان‌نامه‌ها مبتنی بر نرم‌افزار لاتک و بر اساس دستورالعمل مذکور ارائه شده و نحوه‌ی استفاده از قالب به طور مختصر توضیح داده شود. این قالب می‌تواند برای تهیه‌ی پایان‌نامه‌های کارشناسی و کارشناسی ارشد و همچنین رساله‌های دکتری مورد استفاده قرار گیرد.

۵-۱ ساختار پایان‌نامه

این پایان‌نامه در پنج فصل به شرح زیر ارائه می‌شود. نکات اولیه‌ی نگارشی و نحوه‌ی نگارش پایان‌نامه در محیط لاتک در فصل دوم به اختصار اشاره شده است. فصل سوم به مطالعه و بررسی کارهای پیشین مرتبط با موضوع این پایان‌نامه می‌پردازد. در فصل چهارم، نتایج جدیدی که در این پایان‌نامه به دست آمده است، ارائه می‌شود. فصل پنجم به جمع‌بندی کارهای انجام شده در این پژوهش و ارائه‌ی پیشنهادهایی برای انجام کارهای آتی خواهد پرداخت.

^۱ L^AT_EX

^۲ X_EL^AT_EX

^۳ X_QPersian

فصل ۲

مفاهیم اولیه

دومین فصل پایان‌نامه به طور معمول به معرفی مفاهیمی می‌پردازد که در پایان‌نامه مورد استفاده قرار می‌گیرند. در این فصل به عنوان یک نمونه، نکات کلی در خصوص نحوه‌ی نگارش پایان‌نامه و نیز برخی نکات نگارشی به اختصار توضیح داده می‌شوند.

۱-۲ نحوه‌ی نگارش

۱-۱-۲ پرونده‌ها

پرونده‌ی اصلی پایان‌نامه در قالب استاندارد^۱ `thesis.tex` نام دارد. به ازای هر فصل از پایان‌نامه، یک پرونده در شاخه‌ی `chapters` ایجاد نموده و نام آن را در `thesis.tex` (در قسمت فصل‌ها) درج نمایید. برای مشاهده‌ی خروجی، پرونده‌ی `thesis.tex` را با زی‌لاتک کامپایل کنید. مشخصات اصلی پایان‌نامه را می‌توانید در پرونده‌ی `front/info.tex` ویرایش کنید.

۲-۱-۲ عبارات ریاضی

برای درج عبارات ریاضی در داخل متن از `$. ... $` و برای درج عبارات ریاضی در یک خط مجزا از `$$$... $$$` یا محیط `equation` استفاده کنید. برای مثال عبارت $2x + 3y$ در داخل متن و عبارت زیر

$$\sum_{k=0}^n \binom{n}{k} = 2^n \quad (1-2)$$

^۱ قالب استاندارد از گیت‌هاب به نشانی github.com/zarrabi/thesis-template قابل دریافت است.

در یک خط مجزا درج شده است. دقت کنید که تمامی عبارات ریاضی، از جمله متغیرهای تک حرفی مانند x و y باید در محیط ریاضی یعنی محصور بین دو علامت $\$$ باشند.

۲-۱-۳ علائم ریاضی پرکاربرد

برخی علائم ریاضی پرکاربرد در زیر فهرست شده‌اند. برای مشاهده‌ی دستور معادل پرونده‌ی منبع را ببینید.

- مجموعه‌های اعداد: $\mathbb{N}, \mathbb{Z}, \mathbb{Z}^+, \mathbb{Q}, \mathbb{R}, \mathbb{C}$
- مجموعه: $\{1, 2, 3\}$
- دنباله: $\langle 1, 2, 3 \rangle$
- سقف و کف: $\lceil x \rceil, \lfloor x \rfloor$
- اندازه و متمم: $|A|, \overline{A}$
- هم‌نهشتی: $a \equiv 1 \pmod{n}$ یا (پیمانه‌ی n) $a \equiv 1$
- ضرب و تقسیم: \times, \cdot, \div
- سه نقطه: $1, 2, \dots, n$
- کسر و ترکیب: $\frac{n}{k}, \binom{n}{k}$
- اجتماع و اشتراک: $A \cup (B \cap C)$
- عملگرهای منطقی: $\neg p \vee (q \wedge r)$
- پیکان‌ها: $\rightarrow, \Rightarrow, \leftarrow, \Leftarrow, \leftrightarrow, \Leftrightarrow$
- عملگرهای مقایسه‌ای: $\neq, \leq, \not\leq, \geq, \not\geq$
- عملگرهای مجموعه‌ای: $\in, \notin, \setminus, \subset, \subseteq, \subsetneq, \supset, \supseteq, \supsetneq$
- جمع و ضرب چندتایی: $\sum_{i=1}^n a_i, \prod_{i=1}^n a_i$
- اجتماع و اشتراک چندتایی: $\bigcup_{i=1}^n A_i, \bigcap_{i=1}^n A_i$
- برخی نمادها: $\infty, \emptyset, \forall, \exists, \Delta, \angle, \ell, \equiv, \therefore$


۴-۱-۲ لیست‌ها

برای ایجاد یک لیست می‌توانید از محیط‌های «فقرات» و «شمارش» همانند زیر استفاده کنید.

- مورد اول
- مورد دوم
- مورد سوم
- ۱. مورد اول
- ۲. مورد دوم
- ۳. مورد سوم


۵-۱-۲ درج شکل

یکی از روش‌های مناسب برای ایجاد شکل استفاده از نرم‌افزار LaTeX Draw و سپس درج خروجی آن به صورت یک فایل tex درون متن با استفاده از دستور fig یا centerfig است. شکل ۱-۲ نمونه‌ای از اشکال ایجادشده با این ابزار را نشان می‌دهد.



شکل ۱-۲: یک گراف و پوشش رأسی آن

همچنین می‌توانید با استفاده از نرم‌افزار Ipe شکل‌های خود را مستقیماً به صورت pdf ایجاد نموده و آن‌ها را با دستورات img یا centerimg درون متن درج کنید. برای نمونه، شکل ۲-۲ را ببینید.



شکل ۲-۲: نمونه شکل ایجادشده توسط نرم‌افزار Ipe

۶-۱-۲ درج جدول

برای درج جدول می‌توانید با استفاده از دستور «جدول» جدول را ایجاد کرده و سپس با دستور «لوح» آن را درون متن درج کنید. برای نمونه جدول ۱-۲ را ببینید.

جدول ۱-۲: عملگرهای مقایسه‌ای

عنوان	عملگر
کوچک‌تر	<
بزرگ‌تر	>
مساوی	==
نامساوی	<>

۷-۱-۲ درج الگوریتم

برای درج الگوریتم می‌توانید از محیط «الگوریتم» استفاده کنید. یک نمونه در الگوریتم ۱ آمده است.

الگوریتم ۱ پوشش رأسی حریصانه

ورودی: گراف $G = (V, E)$

خروجی: یک پوشش رأسی از G

۱: قرار بده $C = \emptyset$

۲: تا وقتی E تهی نیست:

۳: یال دلخواه $uv \in E$ را انتخاب کن

۴: رأس‌های u و v را به C اضافه کن

۵: تمام یال‌های واقع بر u یا v را از E حذف کن

۶: C را برگردان

۸-۱-۲ محیط‌های ویژه

برای درج مثال‌ها، قضیه‌ها، لم‌ها و نتیجه‌ها به ترتیب از محیط‌های «مثال»، «قضیه»، «لم» و «نتیجه» استفاده کنید. برای درج اثبات قضیه‌ها و لم‌ها از محیط «اثبات» استفاده کنید.

تعریف‌های داخل متن را با استفاده از دستور «مهم» به صورت تیره نشان دهید. تعریف‌های پایه‌ای‌تر را درون محیط «تعریف» قرار دهید.

تعریف ۱-۲ (اصل لانه‌کبوتری) اگر $n + ۱$ کبوتر یا بیش‌تر درون n لانه قرار گیرند، آنگاه لانه‌ای وجود دارد که شامل حداقل دو کبوتر است.

۲-۲ برخی نکات نگارشی

این فصل حاوی برخی نکات ابتدایی ولی بسیار مهم در نگارش متون فارسی است. نکات گردآوری‌شده در این فصل به هیچ وجه کامل نیست، ولی دربردارنده‌ی حداقل مواردی است که رعایت آن‌ها در نگارش پایان‌نامه ضروری به نظر می‌رسد.

۱-۲-۲ فاصله‌گذاری

۱. علائم سجاوندی مانند نقطه، ویرگول، دونقطه، نقطه‌ویرگول، علامت سؤال و علامت تعجب بدون فاصله از کلمه‌ی پیشین خود نوشته می‌شوند، ولی بعد از آن‌ها باید یک فاصله قرار گیرد. مانند: من، تو، او.

۲. علامت‌های پرانتز، آکولاد، کروشه، نقل قول و نظایر آن‌ها بدون فاصله با عبارات داخل خود نوشته می‌شوند، ولی با عبارات اطراف خود یک فاصله دارند. مانند: (این عبارت) یا {آن عبارت}.

۳. دو کلمه‌ی متوالی در یک جمله همواره با یک فاصله از هم جدا می‌شوند، ولی اجزای یک کلمه‌ی مرکب باید با نیم‌فاصله^۲ از هم جدا شوند. مانند: کتاب درس، محبت‌آمیز، دوبخشی.

۴. اجزای فعل‌های مرکب با فاصله از یک‌دیگر نوشته می‌شوند، مانند: تحریر کردن، به سر آمدن.

۲-۲-۲ شکل حروف

۱. در متون فارسی به جای حروف «ك» و «ي» عربی باید از حروف «ک» و «ی» فارسی استفاده شود.

همچنین به جای اعداد عربی مانند ۵ و ۶ باید از اعداد فارسی مانند ۵ و ۶ استفاده نمود. برای این

^۲ «نیم‌فاصله» فاصله‌ای مجازی است که در عین جدا کردن اجزای یک کلمه‌ی مرکب از یک‌دیگر، آن‌ها را نزدیک به هم نگه می‌دارد. معمولاً برای تولید این نوع فاصله در صفحه‌کلیدهای استاندارد از ترکیب Shift+Space استفاده می‌شود.

کار، توصیه می‌شود صفحه‌کلید فارسی استاندارد^۳ را بر روی سیستم خود نصب کنید.

۲. عبارات نقل قول شده یا مؤکد باید درون علامت نقل قول «» قرار گیرند، نه “”. مانند: «کشور ایران».

۳. کسره‌ی اضافی بعد از «ه» غیرملفوظ به صورت «هی» یا «ه» نوشته می‌شود. مانند: خانه‌ی علی، دنباله‌ی فیوناچی.

تبصره: اگر «ه» ملفوظ باشد، نیاز به «ی» ندارد. مانند: فرمانده دلیر، پادشه خوبان.

۴. پایه‌های همزه در کلمات، همیشه «ئ» است، مانند: مسئله و مسئول، مگر در مواردی که همزه ساکن است که در این صورت باید متناسب با اعراب حرف پیش از خود نوشته شود. مانند: رأس، مؤمن.

۳-۲-۲ جدانویسی

۱. علامت استمرار، «می»، توسط نیم‌فاصله از جزء بعدی فعل جدا می‌شود. مانند: می‌رود، می‌توانیم.

۲. شناسه‌های «ام»، «ای»، «ایم»، «اید» و «اند» توسط نیم‌فاصله، و شناسه‌ی «است» توسط فاصله از کلمه‌ی پیش از خود جدا می‌شوند. مانند: گفته‌ام، گفته‌ای، گفته است.

۳. علامت جمع «ها» توسط نیم‌فاصله از کلمه‌ی پیش از خود جدا می‌شود. مانند: این‌ها، کتاب‌ها.

۴. «به» همیشه جدا از کلمه‌ی بعد از خود نوشته می‌شود، مانند: به نام و به آن‌ها، مگر در مواردی که «ب» صفت یا فعل ساخته است. مانند: بسزا، ببینم.

۵. «به» همواره با فاصله از کلمه‌ی بعد از خود نوشته می‌شود، مگر در مواردی که «به» جزئی از یک اسم یا صفت مرکب است. مانند: تناظر یک‌به‌یک، سفر به تاریخ.

۶. علامت صفت برتری، «تر»، و علامت صفت برترین، «ترین»، توسط نیم‌فاصله از کلمه‌ی پیش از خود جدا می‌شوند. مانند: سنگین‌تر، مهم‌ترین.

تبصره: کلمات «بهرتر» و «بهترین» را می‌توان از این قاعده مستثنی نمود.

۷. پیشوندها و پسوندهای جامد، چسبیده به کلمه‌ی پیش یا پس از خود نوشته می‌شوند. مانند: همسر، دانشگاه.

تبصره: در مواردی که خواندن کلمه دچار اشکال می‌شود، می‌توان پسوند یا پیشوند را جدا کرد. مانند: هم‌میهن، هم‌ارزی.

^۳ صفحه‌کلید فارسی استاندارد برای ویندوز، تهیه‌شده توسط بهنام اسفهدی

۸. ضمیرهای متصل چسبیده به کلمه‌ی پیش از خود نوشته می‌شوند. مانند: کتابم، نامت، کلامشان.

فصل ۳

کارهای پیشین

در فصل سوم پایان‌نامه، کارهای پیشین انجام‌شده روی مسئله به تفصیل توضیح داده می‌شود. نمونه‌ای از فصل کارهای پیشین در زیر آمده است.^۱

۳-۱ مسائل خوشه‌بندی

مسئله‌ی خوشه‌بندی^۲ یکی از مهم‌ترین مسائل در زمینه‌ی داده‌کاوی به حساب می‌آید. در این مسئله، هدف دسته‌بندی تعدادی شیء به‌گونه‌ای است که اشیاء درون یک دسته (خوشه)، نسبت به یکدیگر در برابر دسته‌های دیگر شبیه‌تر باشند (معیارهای متفاوتی برای تشابه تعریف می‌گردد). این مسئله در حوزه‌های مختلفی از علوم کامپیوتر از جمله داده‌کاوی، جست‌وجوی الگو^۳، پردازش تصویر^۴، بازیابی اطلاعات^۵ و رایانش زیستی^۶ مورد استفاده قرار می‌گیرد [۷].

تا کنون راه‌حل‌های زیادی برای این مسئله ارائه شده است که از لحاظ معیار تشخیص خوشه‌ها و نحوه‌ی انتخاب یک خوشه، با یکدیگر تفاوت بسیاری دارند. به همین خاطر مسئله‌ی خوشه‌بندی یک مسئله‌ی بهینه‌سازی چندهدفه^۷ محسوب می‌شود.

همان‌طور که در مرجع [۷] ذکر شده است، خوشه در خوشه‌بندی تعریف واحدی ندارد و یکی از

^۱ مطالب این فصل نمونه از پایان‌نامه‌ی آقای بهنام حاتمی گرفته شده است.

^۲ Clustering

^۳ Pattern recognition

^۴ Image analysis

^۵ Information retrieval

^۶ Bioinformatics

^۷ Multi-objective

دلایل وجود الگوریتم‌های متفاوت، همین تفاوت تعریف‌ها از خوشه است. بنابراین با توجه به مدلی که برای خوشه‌ها ارائه می‌شود، الگوریتم متفاوتی نیز ارائه می‌گردد. در ادامه به بررسی تعدادی از معروف‌ترین مدل‌های مطرح می‌پردازیم:

- **مدل‌های مرکزگرا:** در این مدل‌ها، هر دسته با یک مرکز نشان داده می‌شود. از جمله معروف‌ترین روش‌های خوشه‌بندی بر اساس این مدل، خوشه‌بندی k -مرکز، خوشه‌بندی k -میانگین^۸ و خوشه‌بندی k -میان^۹ است.

- **مدل‌های مبتنی بر توزیع نقاط:** در این مدل، دسته‌ها با فرض پیروی از یک توزیع احتمالی مشخص می‌شوند. از جمله الگوریتم‌های معروف ارائه شده در این مدل، الگوریتم بیشینه‌سازی امید ریاضی^{۱۰} است.

- **مدل‌های مبتنی بر تراکم نقاط:** در این مدل، خوشه‌ها متناسب با ناحیه‌های متراکم نقاط در مجموعه داده مورد استفاده قرار می‌گیرد.

- **مدل‌های مبتنی بر گراف:** در این مدل، هر خوشه به مجموعه از رئوس گفته می‌شود که تمام رئوس آن با یک‌دیگر همسایه باشند. از جمله الگوریتم‌های معروف این مدل، الگوریتم خوشه‌بندی HCS^{۱۱} است.

الگوریتم‌های ارائه شده تنها از نظر نوع مدل با یک‌دیگر متفاوت نیستند. بلکه، می‌توان آن‌ها را از لحاظ نحوه‌ی تخصیص نقاط بین خوشه‌ها نیز تقسیم‌بندی کرد:

- **تخصیص قطعی داده‌ها:** در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.

- **تخصیص قطعی داده‌ها با داده‌ی پرت:** در این نوع خوشه‌بندی ممکن است بعضی از داده‌ها به هیچ خوشه‌ای اختصاص نیابد، اما بقیه داده‌ها هر کدام دقیقاً به یک خوشه اختصاص می‌یابد.

- **تخصیص قطعی داده:** در این نوع خوشه‌بندی هر داده دقیقاً به یک خوشه اختصاص داده می‌شود.

- **خوشه‌بندی هم‌پوشان:** در این نوع خوشه‌بندی هر داده می‌تواند به چند خوشه اختصاص داده شود. در گونه‌ای از این مدل، می‌توان هر نقطه را با احتمالی به هر خوشه اختصاص می‌یابد. به این گونه از خوشه‌بندی، خوشه‌بندی نرم^{۱۲} گفته می‌شود.


^۸ k -Means

^۹ k -Median

^{۱۰} Expectation-maximization

^{۱۱} Highly Connected Subgraphs

^{۱۲} Soft clustering



شکل ۳-۱: نمونه‌ای از مسئله‌ی ۲-مرکز

• خوشه‌بندی سلسه‌مراتبی: در این نوع خوشه‌ها، داده‌ها به گونه‌ای به خوشه‌ها تخصیص داده می‌شود که دو خوشه یا اشتراک ندارند یا یکی به طور کامل دیگری را می‌پوشاند. در واقع در بین خوشه‌ها، رابطه‌ی پدر فرزندی برقرار است.


در بین دسته‌بندی‌های ذکر شده، تمرکز اصلی این پایان‌نامه بر روی مدل مرکزگرا و خوشه‌بندی قطعی با داده‌های پرت با مدل k -مرکز است. همان‌طور که ذکر شد علاوه بر مسئله‌ی k -مرکز که به تفصیل مورد بررسی قرار می‌گیرد، k -میانه و k -میانگین از جمله معروف‌ترین خوشه‌بندی‌های مدل مرکزگرا هستند. در خوشه‌بندی k -میانه، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع مربع فاصله‌ی هر نقطه از میانه‌ی نقاط آن خوشه، کمینه گردد. در خوشه‌بندی k -میانگین، هدف افراز نقاط به k خوشه است به گونه‌ای که مجموع فاصله‌ی هر نقطه از میانگین نقاط داخل خوشه (یا مرکز آن خوشه) کمینه گردد.

۳-۲ خوشه‌بندی k -مرکز

یکی از رویکردهای شناخته‌شده برای مسئله‌ی خوشه‌بندی، مسئله‌ی k -مرکز است. در این مسئله هدف، پیدا کردن k نقطه به عنوان مرکز دسته‌ها است به‌طوری‌که شعاع دسته‌ها تا حد ممکن کمینه شود. مثالی از مسئله‌ی ۲-مرکز در شکل ۳-۱ نشان داده شده است. در این پژوهش، مسئله‌ی k -مرکز با متریک‌های خاص و برای k های کوچک مورد بررسی قرار گرفته است و هر کدام از تعریف رسمی مسئله‌ی k -مرکز در زیر آمده است:

مسئله‌ی ۳-۱ (k -مرکز) گراف کامل بدون جهت $G = (V, E)$ با تابع فاصله‌ی d ، که از نامساوی مثلثی پیروی می‌کند داده شده است. زیرمجموعه‌ی $S \subseteq V$ با اندازه‌ی k را به‌گونه‌ای انتخاب کنید که عبارت زیر را کمینه کند:

$$\max_{v \in V} \{ \min_{s \in S} d(v, s) \} \quad (3-1)$$



شکل ۲-۳: نمونه‌ای از مسئله‌ی ۲-مرکز با داده‌های پرت

گونه‌های مختلفی از مسئله‌ی k -مرکز با محدودیت‌های متفاوت توسط پژوهشگران مورد مطالعه قرار گرفته است. از جمله‌ی این گونه‌ها، می‌توان به حالتی که در بین داده‌های ورودی، داده‌های پرت وجود دارد، اشاره کرد. در واقع در این مسئله، قبل از خوشه‌بندی می‌توانیم تعدادی از نقاط ورودی را حذف نموده و سپس به خوشه‌بندی نقاط بپردازیم. سختی این مسئله از آنجاست که نه تنها باید مسئله‌ی خوشه‌بندی را حل نمود، بلکه در ابتدا باید تصمیم گرفت که کدام یک از داده‌ها را به عنوان داده‌ی پرت در نظر گرفت که بهترین جواب در زمان خوشه‌بندی به دست آید. در واقع اگر تعداد نقاط پرتی که مجاز به حذف است، برابر صفر باشد، مسئله به مسئله‌ی k -مرکز تبدیل می‌شود. نمونه‌ای از مسئله‌ی ۲-مرکز با ۷ داده‌ی پرت را در شکل ۲-۳ می‌توانید ببینید. تعریف دقیق‌تر این مسئله در زیر آمده است:

مسئله‌ی ۲-۳ (k -مرکز با داده‌های پرت) یک گراف کامل بدون جهت $G = (V, E)$ با تابع فاصله‌ی d ، که از نامساوی مثلثی پیروی می‌کند داده شده است. زیرمجموعه‌ی $Z \subseteq V$ با اندازه‌ی z و مجموعه‌ی $S \subseteq V - Z$ با اندازه‌ی k را انتخاب کنید به طوری که عبارت زیر را کمینه کند:

$$\max_{v \in V-Z} \{ \min_{s \in S} d(v, s) \} \quad (2-3)$$

گونه‌ی دیگری از مسئله‌ی k -مرکز که در سال‌های اخیر مورد توجه قرار گرفته است، حالت جویبار داده‌ی آن است. در این گونه از مسئله‌ی k -مرکز، در ابتدا تمام نقاط در دسترس نیستند، بلکه به مرور زمان نقاط در دسترس قرار می‌گیرند. محدودیت دومی که وجود دارد، محدودیت حافظه است، به طوری که نمی‌توان تمام نقاط را در حافظه نگه داشت و بعضاً حتی امکان نگه‌داری در حافظه‌ی جانبی نیز وجود ندارد و به طور معمول باید مرتبه‌ی حافظه‌ای کم‌تر از مرتبه حافظه‌ی خطی^{۱۳} متناسب با تعداد نقاط استفاده نمود. از این به بعد به چنین مرتبه‌ای، مرتبه‌ی زیرخطی^{۱۴} می‌گوییم. مدلی که ما در این پژوهش بر روی آن تمرکز داریم مدل جویبار داده تک‌گذره^{۱۵} [؟] است. یعنی تنها یک بار می‌توان از ابتدا تا انتهای داده‌ها را بررسی

^{۱۳} Linear
^{۱۴} sublinear
^{۱۵} Single pass

کرد و پس از عبور از یک داده، اگر آن داده در حافظه ذخیره نشده باشد، دیگر به آن دسترسی وجود ندارد. علاوه بر این، در هر لحظه باید بتوان به پرسمان (برای تمام نقاطی از جویبار داده که تاکنون به آن دسترسی داشته‌ایم) پاسخ داد.

مسئله ۳-۳ (k -مرکز در حالت جویبار داده) مجموعه‌ای از نقاط در فضای d -بعدی به مرور زمان داده می‌شود. در هر لحظه از زمان، به ازای مجموعه‌ی U از نقاطی که تا کنون وارد شده‌اند، زیرمجموعه‌ی $S \subseteq U$ با اندازه‌ی k را انتخاب کنید به طوری که عبارت زیر کمینه شود:

$$\max_{u \in U} \{ \min_{s \in S} d(u, s) \} \quad (3-3)$$

از آنجایی که گونه‌ی جویبار داده و داده پرت مسئله‌ی k -مرکز به علت به‌روز بودن مبحث داده‌های حجیم^{۱۶}، به تازگی مورد توجه قرار گرفته است. در این تحقیق سعی شده است که تمرکز بر روی این گونه‌ی خاص از مسئله باشد. همچنین در این پژوهش سعی می‌شود گونه‌های مسئله را برای انواع متریک‌ها و برای k های کوچک نیز مورد بررسی قرار داد.

۳-۳ مدل جویبار داده

همان‌طور که ذکر شد مسئله‌ی k -مرکز در حالت داده‌های پرت و جویبار داده، گونه‌های تعمیم‌یافته از مسئله‌ی k -مرکز هستند و در حالت‌های خاص به مسئله‌ی k -مرکز کاهش پیدا می‌کنند. مسئله‌ی k -مرکز در حوزه‌ی مسائل ان‌پی-سخت^{۱۷} قرار می‌گیرد و با فرض $P \neq NP$ الگوریتم دقیق با زمان چندجمله‌ای برای آن وجود ندارد [؟]. بنابراین برای حل کارای^{۱۸} این مسائل از الگوریتم‌های تقریبی^{۱۹} استفاده می‌شود.

برای مسئله‌ی k -مرکز، دو الگوریتم تقریبی معروف وجود دارد. در الگوریتم اول، که به روش حریصانه^{۲۰} عمل می‌کند، در هر مرحله بهترین مرکز ممکن را انتخاب می‌کند به طوری تا حد ممکن از مراکز قبلی دور باشد [؟]. این الگوریتم، الگوریتم تقریبی با ضریب تقریب ۲ ارائه می‌دهد. در الگوریتم دوم، با استفاده از مسئله‌ی مجموعه‌ی غالب کمینه^{۲۱}، الگوریتمی با ضریب تقریب ۲ ارائه می‌گردد [؟]. همچنین ثابت شده است، که بهتر از این ضریب تقریب، الگوریتمی نمی‌توان ارائه داد مگر آن‌که $P = NP$ باشد.

^{۱۶} Big data

^{۱۷} NP-hard

^{۱۸} Efficient

^{۱۹} Approximation algorithm

^{۲۰} Greedy

^{۲۱} Dominating set

جدول ۳-۱: نمونه‌هایی از کران پایین تقریب‌پذیری مسائل خوشه‌بندی

مسئله	کران پایین تقریب‌پذیری
k - مرکز	$2[?]$
k - مرکز در فضای اقلیدسی	$1/822[?]$
۱ - مرکز در حالت جویبار داده	$\frac{1+\sqrt{2}}{4}[?]$
k - مرکز با نقاط پرت و نقاط اجباری	$3[?]$

برای مسئله‌ی k - مرکز در حالت جویبار داده برای ابعاد بالا، بهترین الگوریتم موجود ضریب تقریب $2 + \epsilon$ دارد $[?, ?, ?]$ و ثابت می‌شود الگوریتمی با ضریب تقریب بهتر از ۲ نمی‌توان ارائه داد. برای مسئله‌ی k - مرکز با داده‌ی پرت در حالت جویبار داده نیز، بهترین الگوریتم ارائه شده، الگوریتمی با ضریب تقریب $4 + \epsilon$ است که با کران پایین ۳ هنوز اختلاف قابل توجهی دارد $[?]$.

برای k های کوچک به خصوص، $k = 1, 2$ ، الگوریتم‌های بهتری ارائه شده است. بهترین الگوریتم ارائه شده برای مسئله‌ی ۱ - مرکز در حالت جویبار داده برای ابعاد بالا، دارای ضریب تقریب $1/22$ است و کران پایین $\frac{1+\sqrt{2}}{4}$ نیز برای این مسئله اثبات شده است $[?, ?]$. برای مسئله ۲ - مرکز در حالت جویبار داده برای ابعاد بالا، اخیراً راه‌حلی با ضریب تقریب $1/8 + \epsilon$ ارائه شده است $[?]$. برای مسئله‌ی ۱ - مرکز با داده‌ی پرت، تنها الگوریتم موجود، الگوریتمی با ضریب تقریب $1/73$ است $[?]$.

۳-۴ تقریب‌پذیری

یکی از راهکارهایی که برای کارآمد کردن راه‌حل ارائه شده برای یک مسئله وجود دارد، استفاده از الگوریتم‌های تقریبی برای حل آن مسئله است. یکی از عمده‌ترین دغدغه‌های مطرح در الگوریتم‌های تقریبی کاهش ضریب تقریب است. در بعضی از موارد حتی امکان ارائه‌ی الگوریتم تقریبی با ضریبی ثابت نیز وجود ندارد. به طور مثال، الگوریتم تقریبی با ضریب تقریب کم‌تر از ۲، برای مسئله‌ی k - مرکز وجود ندارد مگر این‌که $P = NP$ باشد. برای مسائل مختلف، معمولاً می‌توان کران پایینی برای میزان تقریب‌پذیری آن‌ها ارائه داد. در واقع برای برخی مسائل ان‌پی-سخت، علاوه بر این که الگوریتم کارآمدی وجود ندارد، بعضاً الگوریتم تقریبی با ضریبی تقریب کم و نزدیک به یک نیز وجود ندارد. در جدول ۳-۱ میزان تقریب‌پذیری مسائل مختلفی که در این پایان‌نامه مورد استفاده قرار می‌گیرد را می‌بینید.

فصل ۴

نتایج جدید

در این فصل نتایج جدید به دست آمده در پایان نامه توضیح داده می شود. در صورت نیاز می توان نتایج جدید را در قالب چند فصل ارائه نمود. همچنین در صورت وجود پیاده سازی، بهتر است نتایج پیاده سازی را در فصل مستقلی پس از این فصل قرار داد.

فصل ۵

نتیجه‌گیری

در این فصل، ضمن جمع‌بندی نتایج جدید ارائه‌شده در پایان‌نامه یا رساله، مسائل باز باقی‌مانده و همچنین پیشنهادهایی برای ادامه‌ی کار ارائه می‌شوند.

واژه‌نامه

الف

ابتکاری heuristic.....
 ابعاد بالا high dimensions.....
 اریب bias.....
 آستانه threshold.....
 اصل لانه‌ی کبوتری pigeonhole principle.....
 ان‌پی-سخت NP-Hard.....
 انتقال transition.....

ت

تجربی experimental.....
 تراکم density.....
 تقریب approximation.....
 تقسیم‌بندی partition.....
 توری mesh.....
 توزیع‌شده distributed.....

ب

برخط online.....
 برنامه‌ریزی خطی linear programming.....
 بهینه optimum.....
 بیشینه maximum.....

ج

جدایپذیر separable.....
 جعبه سیاه black box.....
 جویبار داده data stream.....

پ

پرت outlier.....
 پرسمان query.....
 پوشش cover.....
 پیچیدگی complexity.....

ح

حدی extreme.....
 حریصانه greedy.....

خ

خوشه cluster.....
 خطی linear.....

د

داده data
داده‌کاوی data mining
داده‌ی پرت outlier data
دوبرابر سازی doubling
دودویی binary

ر

رأس vertex
رسمی formal

ز

زیرخطی sublinear

س

سرشکن amortized
سلسله‌مراتبی hierarchichal

ش

شبه کد pseudocode
شیء object

ص

صدق‌پذیری satisfiability

غ

غلبه dominate

ف

فاصله distance
فضا space

ق

قطعی deterministic

ک

کارا efficient
کاندیدا candidate
کمینه minimum

م

مجموعه set
مجموعه هسته coreset
سطح planar
موازی سازی parallelization
میان‌گیر buffer

ن

نابه‌جایی inversion
ناوردا invariant
نقطه‌ی مرکزی center point
نیم‌فضا half space

ه

هزینه‌ی آشوب price of anarchy (POA)

ی

یال edge

پیوست آ

مطالب تکمیلی

پیوست‌های خود را در صورت وجود می‌توانید در این قسمت قرار دهید.

Abstract

We present a standard template for typesetting theses in Persian. The template is based on the `XYLATEX Persian` package for the `LATEX` typesetting system. This write-up shows a sample usage of this template.

Keywords: Thesis, Typesetting, Template, `XYLATEX Persian`



Sharif University of Technology
Department of Computer Engineering

M.Sc. Thesis

A Standard Template for Typesetting Theses in Persian

By:

Hamid Zarrabi-Zadeh

Supervisor:

Dr. Supervisor

September 2022